

這份作業要做的是一個 Face De-Identification（人臉去識別化）完整實驗，包含「去識別化 → AI 攻擊 → 防禦 → 報告整理」。作業最後要上傳 程式碼 + Word 詳細報告 + 組員分工表，並壓縮成 TeamName_HW3.zip。

一、作業總目標

你們要完成三件事：

1. Step 1：做人臉去識別化

- 方法一：Blurring，模糊化
- 方法二：Pixelization，馬賽克 / 像素化

2. Step 2：用 AI 攻擊去識別化結果

- 嘗試讓模型從模糊或馬賽克後的臉，仍然辨識出原本是誰。

3. Step 3：用 Differential Privacy 防禦

- 在圖片中加入差分隱私概念的雜訊或擾動，讓 AI 更難認出原始人臉。
-

建議完成方式

Step 0：先準備資料集

建議不要一開始用太大的資料集，不然訓練模型會很痛苦。

你們可以選：

方案 A：AT&T Face Dataset

這個最適合作業，因為：

- 人數少
- 圖片是灰階
- 每個人有多張照片
- 訓練速度快

- 很適合做「辨識這是哪個人」的分類任務

建議格式：

```
dataset/  
  person_1/  
    1.pgm  
    2.pgm  
  person_2/  
    1.pgm  
    2.pgm
```

方案 B：LFW / FaceScrub

比較真實，但資料清理比較麻煩，不建議除非你們時間很多。

Step 1：做人臉去識別化

作業要求你們至少做兩種方法：**blurring** 和 **pixelization**。簡報第 2 頁明確要求使用這兩種方法做人臉去識別化。

1. Pixelization 馬賽克

概念是把圖片切成一格一格，例如：

- $b = 4$
- $b = 8$
- $b = 16$

每一格用同一個顏色或平均值表示。

可以做的實驗參數

方法	參數	意義
----	----	----

Pixelization	$b = 4$	馬賽克較細，還看得出人臉
--------------	---------	--------------

方法 參數 意義

Pixelization $b = 8$ 中等模糊

Pixelization $b = 16$ 很粗，辨識難度較高

簡報第 6 頁也有提醒：pixel size 越小，視覺品質越好；pixel size 越大，去識別化程度越強。

2. Gaussian Blur 高斯模糊

概念是對每個像素附近的區域做加權平均。

可以做的實驗參數

方法 參數 意義

Gaussian Blur $k = 15$ 輕微模糊

Gaussian Blur $k = 45$ 中等模糊

Gaussian Blur $k = 99$ 強烈模糊

簡報第 6 頁也提到，高斯模糊的 $k \times k$ 鄰域越大，圖片會越平滑，視覺品質也會越低。

Step 1 你們報告要呈現什麼？

建議放一張表：

原圖 Pixel $b=4$ Pixel $b=8$ Pixel $b=16$ Blur $k=15$ Blur $k=45$ Blur $k=99$

然後寫一段分析：

當 pixelization 的 b 值越大時，臉部細節越少，去識別化程度越高，但圖片可用性下降。Gaussian blur 的 k 值越大時，人臉輪廓越不清楚，AI 模型辨識難度提高，但人眼也更難理解圖片內容。

Step 2：用 AI 攻擊去識別化圖片

這一步的重點是：

證明就算圖片被模糊或馬賽克，AI 還是可能辨識出原本的人。

簡報第 3 頁要求使用 AI 方法攻擊去識別化系統，嘗試辨識或預測原始臉。

最簡單可行做法

你們可以訓練一個 CNN 分類模型。

任務設定

假設資料集中有 40 個人。

模型輸入：

去識別化後的人臉圖片

模型輸出：

預測這張臉是第幾個人

也就是一個分類問題：

input image $\rightarrow$ CNN $\rightarrow$ person ID

建議訓練資料設計

你們可以建立以下資料：

processed_dataset/

original/

pixel_b4/

pixel_b8/

pixel_b16/

blur_k15/

blur_k45/

blur_k99/

然後分別訓練或測試：

Dataset	說明
---------	----

Original	原始圖片
----------	------

Pixel b=4	輕度馬賽克
-----------	-------

Pixel b=8	中度馬賽克
-----------	-------

Pixel b=16	強度馬賽克
------------	-------

Blur k=15	輕度模糊
-----------	------

Blur k=45	中度模糊
-----------	------

Blur k=99	強度模糊
-----------	------

Step 2 結果要怎麼呈現？

簡報第 8 頁提供的範例是用「Accuracy」比較不同去識別化方法下，AI 還能辨識成功的比例。

你們可以做這種表：

Dataset	Accuracy
---------	----------

Original	95%
----------	-----

Pixel b=4	88%
-----------	-----

Pixel b=8	70%
-----------	-----

Pixel b=16	42%
------------	-----

Blur k=15	80%
-----------	-----

Blur k=45	55%
-----------	-----

Blur k=99	25%
-----------	-----

Random Guess	2.5%
--------------	------

如果是 AT&T dataset，有 40 個人，random guess 就是：

$$1 / 40 = 2.5\%$$

Step 2 報告可以這樣寫

從實驗結果可以發現，當圖片只經過輕度 pixelization 或 Gaussian blur 時，CNN 模型仍然能夠以高於 random guessing 的準確率辨識出原始身分。這代表傳統去識別化方法雖然能降低人眼辨識能力，但不一定能有效防止 AI 模型進行 re-identification attack。

Step 3：用 Differential Privacy 做防禦

這一步是作業最難的地方。

簡報第 4 頁要求你們使用 differential privacy 技術防禦前面的 AI 攻擊，可以選擇重新訓練模型，也可以不重新訓練。

最適合你們的簡化做法

建議不要做太複雜的 DP-SGD。

你們可以做 image-level differential privacy noise。

也就是：

原圖 → 馬賽克或模糊 → 加入 Laplace / Gaussian noise → 得到 DP-obfuscated image

例如：

DP-Pixelization

DP-Gaussian Blur

Differential Privacy 的核心概念

使用參數：

epsilon ϵ

ϵ 越小，代表隱私保護越強，但圖片品質越差。

ϵ 越大，代表圖片品質越好，但隱私保護越弱。

簡報第 10 頁也提醒：**smaller ϵ should have stronger obfuscated degree**，也就是 ϵ 越小，去識別化程度越強。

建議使用的 ϵ 參數

可以測：

ϵ 隱私保護程度 圖片品質

0.1 很強	很差
0.5 中等偏強	中等
1.0 中等	較好
3.0 較弱	較清楚

Step 3 要做什麼實驗？

你們可以比較：

方法	說明
NP-Pix b=16	Non-private pixelization
DP-Pix b=16, $\epsilon=0.1$	加入 DP noise
DP-Pix b=16, $\epsilon=0.5$	加入 DP noise
DP-Pix b=16, $\epsilon=1.0$	加入 DP noise
NP-Blur k=99	Non-private blur
DP-Blur k=99, $\epsilon=0.1$	加入 DP noise

方法	說明
----	----

DP-Blur $k=99$, $\epsilon=0.5$ 加入 DP noise

DP-Blur $k=99$, $\epsilon=1.0$ 加入 DP noise

這個格式跟簡報第 9 頁給的範例很接近。

Step 3 的評估方式

你們要同時看兩件事：

1. AI 攻擊準確率

也就是 CNN 還能不能認出是誰。

理想狀況：

DP 後 Accuracy 下降

例如：

Method	Attack Accuracy
--------	-----------------

NP-Pix $b=16$ 42%

DP-Pix $\epsilon=1.0$ 25%

DP-Pix $\epsilon=0.5$ 15%

DP-Pix $\epsilon=0.1$ 5%

這代表 DP 有效降低 re-identification attack 的能力。

2. 圖片可用性 Utility

簡報第 10 頁建議可以用：

- MSE
- SSIM

來衡量圖片品質。

MSE

MSE 越大，代表圖片跟原圖差越多。

SSIM

SSIM 越高，代表圖片結構跟原圖越相似。

SSIM 越低，代表圖片失真越嚴重。

最終報告建議架構

你們的 Word 報告可以這樣排：

1. Introduction

說明：

- 人臉圖片包含高度敏感的個人資訊
 - 傳統去識別化方法如 blur 和 pixelization 可以降低人眼辨識
 - 但 AI 模型可能仍能進行 re-identification attack
 - 因此本作業比較不同去識別化方法、AI 攻擊效果，以及 differential privacy 防禦效果
-

2. Dataset

寫：

- 使用哪個資料集
- 幾個人
- 每個人幾張圖片
- train/test split 怎麼切

例如：

本實驗使用 AT&T Face Dataset，共 40 位受試者，每位受試者 10 張灰階人臉影像。每位受試者取 8 張作為 training set，2 張作為 testing set。

3. Step 1：Face De-Identification

內容包含：

- Pixelization 方法
 - Gaussian Blur 方法
 - 使用參數
 - 圖片範例
 - 視覺品質分析
-

4. Step 2：AI Re-identification Attack

內容包含：

- CNN 模型架構
 - 訓練方式
 - 評估指標 accuracy
 - 不同去識別化方法的辨識率
 - 分析為什麼輕度去識別化仍容易被辨識
-

5. Step 3：Defense with Differential Privacy

內容包含：

- DP 的基本概念
- ϵ 的意義
- 如何在圖片中加入 noise

- DP-Pixelization / DP-Blur 的結果
 - attack accuracy 是否下降
 - MSE / SSIM 是否變差
-

6. Discussion

可以討論：

- Blur 和 Pixelization 哪個比較安全？
 - 哪個方法圖片品質比較好？
 - AI 攻擊是否比人眼更強？
 - DP 是否有效？
 - ϵ 太小會不會導致圖片完全不可用？
 - 隱私與可用性之間的 trade-off
-

7. Conclusion

可以寫：

本實驗顯示，傳統的 blur 與 pixelization 雖然能降低人眼辨識能力，但在 AI re-identification attack 下仍可能被成功辨識。加入 differential privacy noise 後，模型辨識準確率明顯下降，代表其能提升隱私保護效果。然而，較小的 ϵ 也會造成較大的圖片失真，因此實務上需要在 privacy 與 utility 之間取得平衡。

8. Team Member Responsibilities

作業要求報告中要包含組員分工表。

可以放：

Member Responsibility

A	Dataset preprocessing, pixelization implementation
B	Gaussian blur implementation, result visualization
C	CNN attack model training
D	Differential privacy implementation, MSE/SSIM evaluation
All	Report writing and final discussion

程式碼檔案建議架構

你們可以整理成這樣：

```
TeamName_HW3/  
  code/  
    main.py  
    preprocess.py  
    deidentify.py  
    attack_model.py  
    dp_defense.py  
    evaluate.py  
    utils.py  
  dataset/  
    README.txt  
  results/  
    step1_examples/  
    step2_accuracy.csv  
    step3_dp_results.csv  
    figures/  
  report/  
    HW3_Report.docx  
  README.md
```

建議工作流程

你們可以照這個順序做：

1. 下載並整理人臉資料集
2. 寫 pixelization 和 blur 程式
3. 輸出不同參數的人臉圖片
4. 訓練 CNN 分類器辨識原圖
5. 測試 CNN 對 blur / pixelization 圖片的辨識率
6. 加入 DP noise
7. 測試 DP 後的 AI attack accuracy
8. 計算 MSE 和 SSIM
9. 做表格和圖
10. 寫 Word 報告
11. 壓縮成 TeamName_HW3.zip 上傳 Moodle

最低可交版本

如果你們時間不夠，至少要完成：

1. Pixelization : $b = 4, 8, 16$
2. Gaussian Blur : $k = 15, 45, 99$
3. CNN attack accuracy 表格
4. DP noise : $\varepsilon = 0.1, 0.5, 1.0$
5. MSE / SSIM 表格
6. Word 報告 + 程式碼註解 + 組員分工表

這樣基本上就有完整符合題目的三個步驟。